# 人工智能实训

# 实验项目手册

——基于工业数据集的综合实验

2026 年

# 目 录

**第一章 微型燃气轮机电能输出预测实验** ..... 4

1.1 工业背景与问题描述 ..... 4

1.2 数据集基本情况介绍 ..... 4

1.3 数据分析任务 ..... 5

1.4 数据集下载链接与文献引用 ..... 8

**第二章 风电数据特性分析与功率预测实验** ..... 10

2.1 工业背景与问题描述 ..... 10

2.2 数据集基本情况介绍 ..... 10

2.3 数据分析任务 ..... 11

2.4 数据集下载链接与文献引用 ..... 15

**第三章 滚动轴承剩余使用寿命预测实验** ..... 17

3.1 工业背景与问题描述 ..... 17

3.2 数据集基本情况介绍 ..... 17

3.3 数据分析任务 ..... 19

3.4 数据集下载链接与文献引用 ..... 24

**第四章 变转速条件下轴承振动信号分析实验** ..... 26

4.1 工业背景与问题描述 ..... 26

4.2 数据集基本情况介绍 ..... 26

4.3 数据分析任务 ..... 28

4.4 数据集下载链接与文献引用 ..... 32

**第五章 锂离子电池退化与健康状态分析实验** ..... 34

5.1 工业背景与问题描述 ..... 34

5.2 数据集基本情况介绍 ..... 34

5.3 数据分析任务 ..... 36
5.4 数据集下载链接与文献引用 ..... 40
**第六章 粒子加速器电源系统故障分类实验** ..... 42
6.1 工业背景与问题描述 ..... 42
6.2 数据集基本情况介绍 ..... 42
6.3 数据分析任务 ..... 43
6.4 数据集下载链接与文献引用 ..... 47
**第七章 火力发电厂蒸汽量软测量实验** ..... 48
7.1 工业背景与问题描述 ..... 48
7.2 数据集基本情况介绍 ..... 48
7.3 数据分析任务 ..... 49
7.4 数据集下载链接与文献引用 ..... 51
公式章 1 节 1 ..... 53
**附录 实验环境配置与依赖库说明** ..... 53
Python 环境要求 ..... 53
必需的 Python 库 ..... 53
库功能说明 ..... 53

# 第一章 微型燃气轮机电能输出预测实验

## 1.1 工业背景与问题描述

微型燃气轮机（Micro Gas Turbine, MGT）是一种小型化燃气发电装置，凭借其紧凑的结构设计、多燃料适应性及低排放特性，广泛应用于分布式能源系统、应急备用电源、工业余热回收发电及冷热电三联供等场景，可有效满足电网调峰需求、提供关键负荷备用电力，并支撑可再生能源高比例接入下的分散式发电模式。准确预测微型燃气轮机的电能输出功率，对于优化能源调度策略、实现精准的系统闭环控制、提升设备运行效率，以及建立早期故障预警机制具有重要的理论价值与工程实践意义。

在实际运行中，燃气轮机的电能输出受到输入控制信号的影响，但由于热力学惯性、机械延迟等因素，输出电能相对于输入控制信号存在明显的时滞特性。此外，测量过程中不可避免地会引入噪声干扰，影响数据分析的准确性。因此，本实验的核心问题包括：1） 如何通过数据分析揭示输入-输出的动态响应关系；2） 如何有效去除测量噪声；3） 如何建立准确的电能输出预测模型。

## 1.2 数据集基本情况介绍

（1）数据集名称：Micro Gas Turbine Electrical Energy Prediction Dataset

（2）数据来源：德国卡尔斯鲁厄理工学院（Karlsruhe Institute of Technology）

（3）采样设备：3 千瓦商用微型燃气轮机

（4）总样本数：71,225 条记录

（5）数据描述：该数据集包含 8 个时间序列，反映了燃气轮机在不同条件下的行为模式。每个时间序列代表一个独立的实验，输入控制电压随时间变化，测量微型燃气轮机产生的输出功率。时间序列持续时间从 6,495 到 11,820 个数据点不等，分辨率约为 1 秒，约对应 1.8 至 3.3 小时。存在矩形时间序列和连续时间序列，矩形序列中输入信号瞬时变化，输出存在明显延迟；连续序列中输入信号渐变变化，输出无明显延迟。图 1 展示了输入控制信号与输出响应信号的时间序列图。

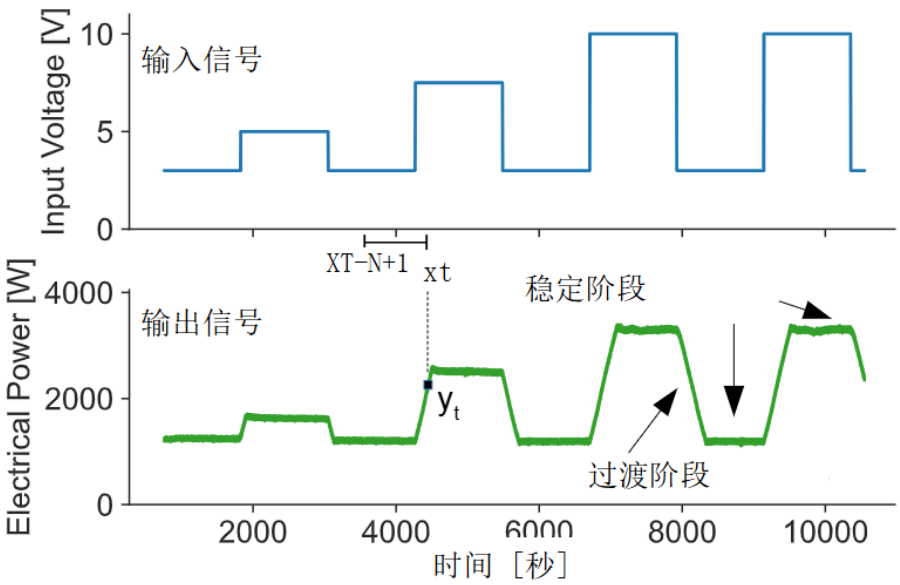


图 1 输入控制信号与输出响应信号的时间序列图

（6）数据集特点：1）无缺失值；2）时间序列数据，具有时序相关性；3）存在明显的输入-输出时滞特性。

（7）特征说明：

| 特征名称 | 数据类型 | 角色 | 说明 |
|---|---|---|---|
| time | 连续值 | ID | 时间戳（单位：秒） |
| input_voltage | 连续值 | 特征 | 输入控制电压（单位：伏特） |
| el_power | 连续值 | 目标变量 | 输出电功率（单位：瓦特） |

## 1.3 数据分析任务

**任务 1：数据统计分析与可视化**

【任务目标】全面了解数据集的基本统计特征，通过可视化手段直观展示时间序列的变化规律和输入-输出关系。

【采用方法】

1）描述性统计分析：均值、标准差、最值、四分位数。

2）时间序列可视化：折线图展示原始数据。

3）散点图分析：输入-输出关系可视化。

【具体步骤】

1）加载数据集，查看数据基本信息（shape、数据类型）。

2）计算描述性统计量：对 input_voltage 和 el_power 分别计算均值、标准差、最小值、最大值、四分位数（Q1、Q2、Q3）。

3）绘制时间序列图：以 time 为横轴，分别绘制 input_voltage 和 el_power 的时间序列折线图，使用双 Y 轴在同一图中展示两个变量的变化。

4）绘制散点图：以 input_voltage 为横轴，el_power 为纵轴绘制散点图，观察两者之间的相关性趋势。

【评分建议】

1）描述性统计表完整性（5 分）

2）时间序列图清晰度与标注（5 分）

3）散点图及趋势线（5 分）

**任务 2：数据去噪处理**

【任务目标】去除测量噪声对数据分析的影响，获得更平滑的时间序列数据。

【采用方法】

等宽分箱法：将数据划分为若干个等宽的区间，用区间内数据的统计值（如均值或中位数）代替原始值，达到平滑效果。

【具体步骤】

1）选择一条矩形变化的时间序列（如 ex_1.csv）。

2）实现等宽分箱算法：设定分箱数量（如每 50 个连续数据点为一个箱子），计算每个箱内 el_power 的均值，用均值替换箱内所有原始值。

3）对比去噪前后的时间序列图。

4）尝试不同的分箱宽度（如 30、50、100），比较去噪效果。

【评分建议】

1）分箱算法实现正确性（5 分）

2）去噪前后对比图（5 分）

3）不同分箱宽度效果分析（5 分）

**任务 3：相关性分析**

【任务目标】量化输入电压 input_voltage 与输出功率 el_power 之间的相关程度，为后续建模提供依据。

【采用方法】

互相关分析：衡量两个时间序列变量在不同时间偏移（时滞）下的线性相关程度，识别变量间的动态响应关系、领先-滞后特性及系统传递延迟。

【具体步骤】

1）计算互相关系数：设定最大时滞范围（如±50 个采样点，或依据系统响应特性设定），逐点计算不同时滞下的标准化互相关系数，并画出互相关系数随迟延变化的趋势图。

2）识别相关系数峰值与延迟时间：确定互相关系数峰值及其对应的响应延迟时间，并确定相关性强弱（例如，≥0.7 为强相关，0.4−0.7 为中等相关，<0.4 为弱相关）和方向（正、负）。

3）分析结果：输入电压与输出功率的最优时滞及关联程度，相关性强弱对动态预测模型输入历史样本选择的启示。

【评分建议】

1）互相关系数及峰值计算正确性（5 分）

2）互相关系数随迟延变化图（10 分）

3）结果分析与解释（5 分）

**任务 4：回归分析与电能输出预测**

【任务目标】建立输入电压到输出电功率的预测模型，评估模型性能。

【采用方法】

1）最小二乘线性回归（Ordinary Least Squares, OLS）：建立线性预测模型。

2）支持向量回归（Support Vector Regression, SVR）：建立非线性预测模型。

【具体步骤】

1）数据准备：选择训练集（如 experiments 1, 9, 20, 21, 23, 24），选择测试集（如 experiments 4, 22），分离特征 X（input_voltage）和目标变量 y（el_power）。

2）最小二乘线性回归（OLS）：在训练集上训练模型，获取模型参数（斜率和截距），并在测试集上进行预测。

3）支持向量回归（SVR）：选择核函数（如 RBF），设置超参数（如 C=1.0, epsilon=0.1），在训练集上训练模型，并在测试集上进行预测。

4）模型评估与对比：计算均方根误差 RMSE 和平均绝对误差 MAE，绘制预测值 vs 真实值散点图，对比两种模型的预测效果。

【评分建议】

1） 线性回归模型实现（15 分）

2）SVR 模型实现（15 分）

3）RMSE/MAE 计算（10 分）

4）模型对比分析（10 分）

## 1.4 数据集下载链接与文献引用

【数据集下载】

1）UCI Machine Learning Repository

https://archive.ics.uci.edu/dataset/994/micro+gas+turbine+electrical+energy+prediction

2）直接下载链接

https://archive.ics.uci.edu/static/public/994/micro+gas+turbine+electrical+energy+prediction.zip

【文献】

Pawel Bielski, Aleksandr Eismont, Jakob Bach, Florian Leiser, Dustin Kottonau, and Klemens Böhm. Knowledge-Guided Learning of Temporal Dynamics and its Application to Gas Turbines. 15th ACM International Conference on Future Energy Systems (e-Energy '24), Singapore, 2024.

# 第二章 风电数据特性分析与功率预测实验

## 2.1 工业背景与问题描述

风电作为一种清洁可再生能源，在电力系统中的占比逐年提升。然而，风电的间歇性和波动性给电网调度带来巨大挑战。准确预测风电功率输出，对于提高风电消纳能力、优化发电计划、保障电网安全稳定运行具有重要意义。

在实际运行中，风电功率受到风速、风向、温度、湿度、气压等多种气象因素的影响，其中风速与功率之间存在三次方关系：

$$P = \frac{1}{2} C_p \rho S v^3 \tag{1.1}$$

其中，$P$ 是风能转化成的机械能的功率；$C_p$ 功率系数，取决于风车的设计和效率；$\rho$ 是空气密度，受温度、湿度和压强的影响；$S$ 是风轮叶片扫过的面积；$v$ 是风速。

由于传感器故障、通信干扰、弃风限电等原因，原始数据中常存在大量异常值和缺失值，严重破坏了风速与功率应有的分布规律和对应关系，需要对风电场数据进行数据清洗和预处理，再建立风电功率预测模型。因此，本实验的核心问题包括：1）如何有效清洗风电场数据中的缺失值和异常值；2）如何分析各气象特征与风电功率的相关性；3）如何对不同工况下的风电数据进行聚类划分；4）如何建立高精度的风电功率预测模型。

## 2.2 数据集基本情况介绍

（1）数据集名称：Wind Power Prediction Dataset

（2）数据来源：西班牙索塔文托风电场

（3）采样设备：风力涡轮机

（4）采样频率：15 分钟/点（每天 96 个采样点）

（5）数据描述：数据集包含风速、风向、温度、湿度、压强 5 个气象特征，以及对应的风电功率输出值。

（6）数据集特点：1）存在缺失值和异常值；2）特征间存在非线性关系；3）风速与功率呈现明显三次方关系；4）时间序列数据，具有时序相关性。

（7）特征说明：

| 特征名称 | 数据类型 | 角色 | 说明 |
|---|---|---|---|
| time | 时间戳 | ID | 采样时间点（单位：分钟） |
| wind_speed | 连续值 | 特征 | 风速（单位：米/秒） |
| wind_direction | 连续值 | 特征 | 风向（单位：度） |
| temperature | 连续值 | 特征 | 环境温度（单位：摄氏度） |
| humidty | 连续值 | 特征 | 相对湿度（单位：百分比） |
| Pressure | 连续值 | 特征 | 大气压强（单位：帕斯卡） |
| power | 连续值 | 目标变量 | 风电输出功率（单位：kW） |

## 2.3 数据分析任务

**任务 1：数据预处理**

【任务目标】掌握风电场数据清洗和预处理方法，通过可视化手段直观展示风电场数据的分布特点，完成缺失值填充、异常值检测与去除、数据归一化，获得高预处理后的数据集。

【采用方法】

1）缺失值清洗：前向填充或插值法填补缺失值。

2）异常值清洗：结合物理规则（功率负值剔除）和 DBSCAN 密度聚类算法识别风速-功率空间中的离群点。

3）数据归一化：Min-Max 归一化消除量纲影响，统一缩放至[0,1]区间。

【具体步骤】

1）数据加载与可视化：读取风电场数据集，查看各数据数据基本信息，包括数据类型、缺失值数量与占比统计。同时，绘制各属性随时间变化的波形图，观察

数据的变化趋势、周期性规律以及是否存在明显的异常波动，为后续处理提供直观依据。

2）缺失值填充：对于短时孤立缺失（如连续 1~5 个点），采用前向填充法（Forward Fill），即用缺失值前一时刻的观测值来填补当前缺失位置；对于连续较长的缺失区间（如超过 5 个点），可采用 K 近邻填充法。

3）物理异常值剔除：删除功率列中的负值等明显违反物理规律的数据点。

4）DBSCAN 聚类去噪：选择风速和功率作为特征，使用 DBSCAN 算法（需调优 epsilon 和 min_pts 参数）识别低密度区域的噪声点，去除标签为-1 的异常点。

5）数据归一化：对训练集进行 Min-Max 归一化，将各特征数值缩放到[0, 1]区间，记录归一化参数。后续任务对测试集进行归一化时，直接使用训练集的归一化参数进行转换。

【评分建议】

1）缺失值填充（5 分）

2）异常值检测与清洗（含 DBSCAN 实现）（10 分）

3）数据归一化实现（5 分）

**任务 2：可视化与相关性分析**

【任务目标】全面了解风电数据的统计特征，通过可视化手段直观展示各特征与功率的关系，量化气象特征与风电功率的相关程度，筛选关键预测特征。

【采用方法】

1）描述性统计分析：均值、极差、标准差。

2）可视化分析：风速-功率、风向-功率关系可视化、风速频率直方图、风向频率直方图、风向玫瑰图。

3）相关性分析：皮尔逊相关系数衡量线性关系，设定阈值筛选关键特征。

【具体步骤】

1）计算统计特征：计算训练数据集中每个变量的均值（mean）、极差（range）、标准差（std）、四分位数（Q1/Q2/Q3），生成统计特征表。

2）绘制散点图矩阵：绘制六维特征（风速、风向、温度、湿度、压强、功率）的散点图矩阵，矩阵对角线位置可放置各特征的频率分布直方图，观察各气象特征与功率的散点分布形态，识别非线性关系、聚类趋势及异常点分布；分析特征间的关联关系。

3）风向玫瑰图：按 15 度为一个区间绘制风向玫瑰图，展示风向频率分布。

4）相关性计算与特征筛选：计算六维特征的皮尔逊相关系数矩阵，绘制热力图（Heatmap）；提取各特征与功率的相关系数，按绝对值降序排列；设定相关系数绝对值阈值（≥0.2），保留满足条件的特征；结合散点图矩阵观察结果，解释各筛选特征与功率的物理相关性（如风速-功率的立方关系、温度-功率的负相关等）。

【评分建议】

1）统计特征表（5 分）

2）六维特征散点图矩阵（5 分）

3）风向玫瑰图（5 分）

4）相关系数热力图与特征筛选（10 分）

**任务 3：风电数据 K-means 聚类分析**

【任务目标】使用 K-means 聚类算法对风电数据进行工况划分，识别不同运行模式，分析各类别特征差异。

【采用方法】

1）K-means 聚类：基于划分的聚类算法，将数据划分为 $K$ 个簇，使簇内样本相似度高，簇间相似度低。

2）最优 $K$ 值确定：肘部法（SSE 曲线）与轮廓系数法相结合，综合确定最佳聚类数。

【具体步骤】

1）特征选择：基于任务 2 筛选的特征，结合风速和功率进行聚类（使用归一化后的数据）。

2）肘部法确定 $K$ 值：计算不同 $K$ 值（2-10）下的 SSE（误差平方和），绘制 SSE 随 K 值变化曲线，寻找肘部点确定最佳聚类数。

3）轮廓系数法验证：计算不同 $K$ 值下的平均轮廓系数，绘制轮廓系数曲线，与肘部法结果对比验证，确定最优 $K$ 值。

4）执行聚类：使用最优 $K$ 值进行 K-means 聚类，保存各样本的类别标签。

5）结果可视化：绘制风速-功率散点图，不同簇用不同颜色标记。

【评价指标】

1）肘部法与轮廓系数法确定 $K$ 值（15 分）

2）聚类结果可视化与分析（5 分）

**任务 4：风电场风电功率预测**

【任务目标】建立风电功率预测模型，对每一类数据分别训练，评估不同模型的预测性能，对比不同模型的预测效果。

【采用方法】

1）支持向量回归（Support Vector Regression, SVR）：适用于小样本非线性回归问题，通过核函数映射到高维空间。

2）BP 神经网络（Back Propagation Neural Network, BP）：多层前馈网络，通过误差反向传播调整权值，可逼近任意非线性函数。

3) LSTM 神经网络（Long Short-Term Memory, LSTM）：适用于时间序列预测，通过门控机制捕捉长期依赖关系。

4）评价指标：平均绝对误差（MAE）反映预测误差的平均水平，均方根误差（RMSE）对大误差更敏感，判定系数（$R^2$）反映模型对数据变异的解释程度。

【具体步骤】

1）数据准备：基于任务 3 的聚类结果，将数据按类别划分，对每个类别分别划分训练集和测试集（使用归一化数据）。

2）支持向量回归（SVR）：选择核函数（如 RBF），设置超参数（如 C=1.0, epsilon=0.1），在训练集上训练模型，并在测试集上进行预测。

3）BP 神经网络（BP）：设计网络结构，输入层（特征数）、隐藏层（2 层，每层 32 个神经元）、输出层（1 个神经元），设置激活函数（ReLU）、优化器（Adam）、学习率（0.001），在训练集上训练模型，并在测试集上进行预测。

4）LSTM 神经网络：构造时间序列样本（3D 输入，即样本数、时间步、特征数），设置 LSTM 层（64 个单元）、Dropout 层（0.2）、全连接层，在训练集上训练模型，并在测试集上进行预测。

5）模型评估与对比：计算各模型的 MAE、RMSE、$R^2$，绘制预测值-时间和真实值-时间的曲线图，对比三种模型的预测效果。

【评价指标】

1）SVR 模型实现（10 分）

2）BP 模型实现（10 分）

3）LSTM 模型实现（10 分）

4）MAE/RMSE/$R^2$计算与对比分析（5 分）

## 2.4 数据集下载链接与文献引用

【数据集下载】

https://www.sotaventogalicia.com/en/technical-area/real-time-data/historical/

【文献】

[1] Min Ding, Hao Zhou, Hua Xie, Min Wu, Yosuke Nakanishi, Ryuichi Yokoyama. A gated recurrent unit neural networks based wind speed error correction model for short-term wind power forecasting[J]. *Neurocomputing*, 2019, 366: 245-254.

[2] Min Ding, Ji Lv, Sibei Zhou, Junhao Li, Zhijian Fang, Ryuichi Yokoyama. A decomposition and reconstruction based hybrid time series model for short-term wind power forecasting[J]. *Journal of Advanced Computational Intelligence and Intelligent Informatics*, 2025, 29(3): 592-602.

# 第三章 滚动轴承剩余使用寿命预测实验

## 3.1 工业背景与问题描述

滚动轴承是旋转机械中最关键的零部件之一，广泛应用于风力发电机、高铁列车、航空发动机、工业电机等设备中。轴承一旦发生故障，可能导致整个设备停机，造成巨大的经济损失甚至安全事故。因此，准确预测轴承的剩余使用寿命（Remaining Useful Life, RUL）对于实施预测性维护、降低维修成本、提高设备可靠性具有重要意义。

在实际工业场景中，轴承的退化是一个缓慢积累的过程。通过监测轴承运行过程中的振动信号，可以捕捉其健康状态的渐变信息。本实验基于 XJTU-SY 轴承加速寿命试验数据集，模拟工业现场轴承从正常运行到完全失效的全过程，通过分析振动信号的变化规律，建立 RUL 预测模型，为设备预测性维护提供决策支持。

## 3.2 数据集基本情况介绍

（1）数据集名称：XJTU-SY 滚动轴承加速寿命实验数据集

（2）数据来源：西安交通大学

（3）试验平台：试验平台由交流（AC）感应电机、电机转速控制器、转轴、支撑轴承（重型滚子轴承）、液压加载系统及测试轴承组成，可开展滚动轴承在不同工况下的加速寿命试验，获取测试轴承全寿命周期监测数据。图 3 展示了滚动轴承加速寿命试验台。平台可调节的工况主要包括径向力和转速：径向力由液压加载系统产生，作用于测试轴承座上；转速由交流电机的转速控制器设定与调节。轴承型号：LDK UER204 滚动轴承。

两个 PCB 352C33 型加速度计以 90°角安装在被测轴承的外壳上（分别安装在水平轴和垂直轴），分别采集通道 1：水平方向振动信号、通道 2：垂直方向振动信号。

加速退化实验共设置了 3 种不同的工作条件，每种工作条件下测试了 5 个轴承。工作条件包括：（1）2100 转/分钟（35 赫兹）和 12 千牛;（2）2250 转/分钟（37.5 赫兹）和 11 千牛;（3）2400 转/分（40 赫兹）和 10 千牛。

| 工况编号 | 转速 | 径向载荷 | 测试轴承数量 |
| --- | --- | --- | --- |
| 工况 1 | 2100 rpm （35 Hz） | 12 kN | 5 个 |
| 工况 2 | 2250 rpm （37.5 Hz） | 11 kN | 5 个 |
| 工况 3 | 2400 rpm （40 Hz） | 10 kN | 5 个 |

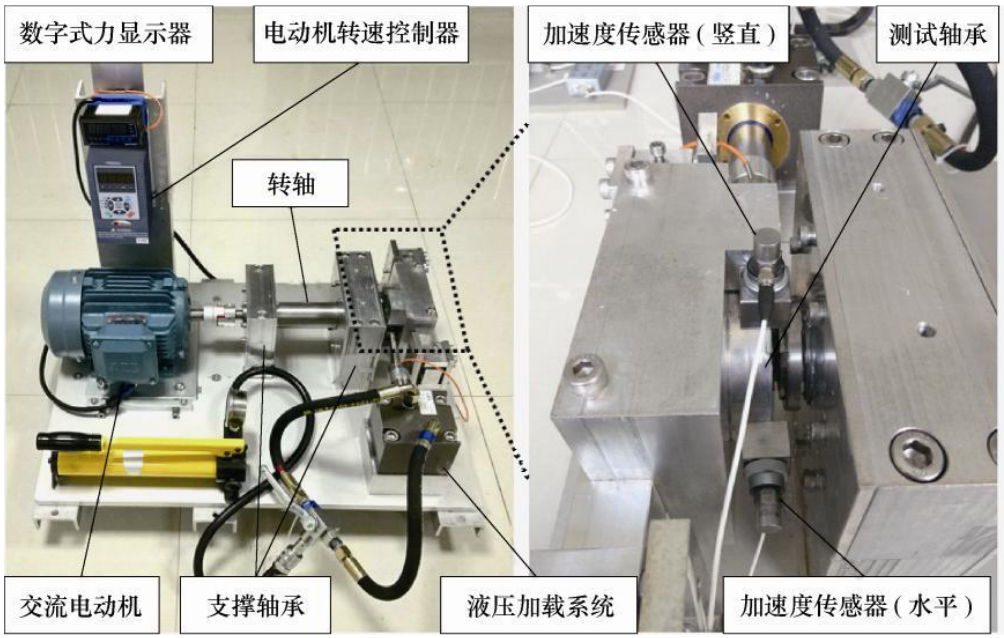


图 3 XJTU-SY 滚动轴承加速寿命试验台示意图

（4）数据规模与采用说明：

1）包含 15 个滚动轴承的全寿命运行数据（从正常运行到完全失效）。

2）每个轴承的采样次数从 100+到 2000+不等，总计超过 15000 个数据文件。

3）每个数据文件包含 32768 个采样点。

4）采样频率：25.6 kHz。

5）每采样时长：1.28 秒（32768 个数据点）。

6）采样间隔：1 分钟。

7）数据格式：CSV 文件，每行包含水平振动和垂直振动两列数据。

8）故障类型：数据集中的轴承失效模式包括内圈磨损、保持架断裂、外圈磨损、外圈断裂等。

| 工况 | 数据集 | 样本总数 | 基本额定寿命 | 实际寿命 | 失效位置 |
|---|---|---|---|---|---|
| 1 | Bearing 1_1 | 123 | 5.600~9.677h | 2h3min | 外圈 |
| | Bearing 1_2 | 161 | | 2h41min | 外圈 |
| | Bearing 1_3 | 158 | | 2h38min | 外圈 |
| | Bearing 1_4 | 122 | | 2h2min | 保持架 |
| | Bearing 1_5 | 52 | | 52min | 内圈、外圈 |
| 2 | Bearing 2_1 | 491 | 6.786~11.726h | 8h11min | 内圈 |
| | Bearing 2_2 | 161 | | 2h41min | 外圈 |
| | Bearing 2_3 | 533 | | 8h53min | 保持架 |
| | Bearing 2_4 | 42 | | 42min | 外圈 |
| | Bearing 2_5 | 339 | | 5h39min | 外圈 |
| 3 | Bearing 3_1 | 2538 | 8.468~14.632h | 42h18min | 内圈、滚动体、保持架、外圈 |
| | Bearing 3_2 | 2496 | | 41h36min | 外圈 |
| | Bearing 3_3 | 371 | | 6h11min | 内圈 |
| | Bearing 3_4 | 1515 | | 25h15min | 内圈 |
| | Bearing 3_5 | 114 | | 1h54min | 外圈 |

## 3.3 数据分析任务

**任务 1：数据频谱分析与可视化**

【任务目标】通过振动信号时域波形与频谱分析，深入理解轴承振动信号的时域统计特征与频域分布规律，识别轴承故障特征频率，观察轴承退化过程中振动信号的变化趋势。

【采用方法】

1）时域波形绘制：针对不同退化阶段绘制时间序列波形图，并进行对比分析，以定性判断轴承健康状态的演变。

2）频谱分析：通过快速傅里叶变换（FFT）将时域信号转换为频域表示，揭示信号的频率成分构成。频谱分析是识别故障特征频率的核心手段。

【具体步骤】

1）选择数据集：Bearing1-3，对应工况为 2100 rpm（35Hz），径向载荷为 12kN，失效模式为外圈磨损，含 158 个 CSV 文件（对应 2 小时 38 分钟寿命周期）。

2）波形图绘制：绘制正常状态、中期退化状态、失效前状态的时域波形对比图，例如可以选择 1.csv、80.csv、150.csv，分别对应早期（0min）、中期（80min）、末期（150min，失效前 8min），计算并标注 RMS 值。

3）频谱图绘制：对上述三种状态的信号进行 FFT 变换，绘制幅值频谱图（0-1000 Hz 范围），统一纵轴量纲，便于对比。

4）结果分析：记录实测谱峰，并在频谱图上标注。对比三阶段频谱能量分布变化。预期结果为：正常状态下，频谱以转频及其谐波为主，幅值较低；退化状态下，故障特征频率及其边频带逐渐显现，幅值增大；失效前，振动幅值显著增加，频谱复杂化。

【评分建议】

1）至少三个时域波形图（5 分）

2）频谱分析图与谱峰（5 分）

3）不同阶段下的频谱能量分布变化分析（5 分）

**任务 2：基于小波变换的数据去噪**

【任务目标】掌握小波阈值去噪的基本原理与实现步骤。评估去噪处理对轴承故障特征提取的改善效果，验证能否有效抑制高频随机噪声同时保留关键冲击特征。

【采用方法】离散小波变换（DWT）：采用离散小波变换（DWT）结合软阈值去噪策略，对含噪振动信号进行多分辨率分解与重构，实现信噪分离。

【具体步骤】

1）确定去噪对象：选用 Bearing 1-3 的 155.csv 文件（失效前约 3 分钟）。该文件处于外圈故障严重退化阶段，信号中包含强背景噪声与明显的周期性冲击脉冲，是去噪处理的典型对象。

2）小波分解：加载一条振动信号，选用一种小波基函数（db4、sym8、coif3 等）对信号进行分解（建议 5 层），得到 1 个近似系数 a5 和 5 个细节系数 d1 至 d5。

db4 小波具有紧支撑性和良好的时频局部化特性，适合捕捉轴承故障产生的瞬态冲击成分。

3）阈值处理：对各层细节系数分别计算噪声标准差估计值，确定各层阈值 $\lambda$。应用软阈值函数处理细节系数：当系数绝对值小于 $\lambda$ 时置为零，大于 $\lambda$ 时则减去 $\lambda$ 符号值。保留近似系数不变。

4）信号重构：利用处理后的近似系数 a5 和细节系数 d1'至 d5'进行小波逆变换，重构出去噪后的振动信号。

5）效果对比：在时域绘制原始信号与去噪信号的波形对比图，观察去噪后冲击脉冲的清晰度和基线平稳性。在频域分别计算两者的 FFT 幅值谱，重点对比谱峰尖锐程度和信噪比改善情况。

6）量化评估：计算信噪比（SNR = 10·log10(信号功率/噪声功率)）评估噪声抑制效果。计算均方根误差（RMSE）衡量去噪信号与原始信号的偏差。

【评分建议】

1）通过小波变换获得重构后的去噪信号（10 分）

2）分析原始信号与去噪信号的频谱差异（5 分）

3）计算信噪比（SNR）和均方根误差（RMSE）（5 分）

**任务 3：特征提取与降维**

【任务目标】构建轴承全寿命周期的时域特征空间。掌握主成分分析（PCA）降维方法。实现退化轨迹的可视化表达，验证能否清晰区分正常、退化、失效三个阶段。为任务 4 的 RUL 预测建立低维、有效的特征输入。

【采用方法】

1）时域特征：均值、标准差、峰值、峰峰值、均方根值、波形因子、峰值因子、脉冲因子、裕度因子等。

2）降维方法：通过主成分分析（PCA）将高维特征投影至低维空间，揭示退化主导因素。

3）可视化：PCA 散点图、特征趋势图。

【具体步骤】

1）批量特征提取：遍历 1.csv 至 158.csv。对每个文件计算上述 9 个时域特征。按时间顺序构建特征矩阵 X（158 行×9 列）。时域特征列表如下：

| 特征名称 | 物理意义 |
|---|---|
| 均值 | 信号的中心位置 |
| 标准差 | 信号的离散程度 |
| 峰值 | 信号的最大幅值 |
| 峰峰值 | 信号的波动范围 |
| 均方根值 | 信号的能量 |
| 波形因子 | 波形与正弦波的差异 |
| 峰值因子 | 冲击特性 |
| 脉冲因子 | 脉冲特性 |
| 裕度因子 | 对冲击的敏感度 |

2）数据标准化：计算各特征列的均值和标准差，进行 Z-score 标准化。

3）PCA 计算：计算标准化矩阵的协方差矩阵。进行特征值分解，获取特征向量与特征值。将数据投影至前 3 个主成分空间。

4）结果可视化：退化轨迹图：绘制主元 1（PC1）-主元 2（PC2）二维散点图，158 个点按时间顺序连线，观察从起点到终点的迁移路径。方差贡献图：绘制各主成分方差贡献率柱状图，标注累计贡献率曲线。载荷分析：绘制特征-主成分载荷图，分析 PC1 与 RMS、峰值的相关性。

5）退化阶段结果分析：在 PC1-PC2 图上用不同颜色标注三阶段区域：早期（1-50）、中期（51-120）、末期（121-158）。观察三类样本点的空间分布是否形成明显分区。PC1 主要反映振动能量增长，与 RMS、峰值、峰峰值呈强正相关。PC2 解释方差主要反映信号冲击特性变化，与峰值因子、脉冲因子相关性较高。理

论上，退化轨迹从第 1 点向第 158 点延伸，早期点聚集，中期均匀分布，末期快速偏离原点。

【评分建议】

1）时域特征提取（10 分）

2）PCA 降维与结果可视化（10 分）

3）退化阶段结果分析（5 分）

**任务 4：回归分析**

【任务目标】建立轴承剩余使用寿命（RUL）预测模型。验证时域特征对寿命预测的适用性。比较最小二乘回归、岭回归和支持向量回归三种算法的预测精度，评估模型在寿命不同阶段的预测可靠性。

【采用方法】

1）最小二乘回归（OLS）：建立基线模型，检验特征与 RUL 的线性关系。

2）岭回归（Ridge Regression）：在普通最小二乘法基础上加入 L2 正则化项，通过惩罚大系数防止过拟合，适用于特征间存在多重共线性的场景。

3）支持向量回归（Support Vector Regression, SVR）：采用核函数将特征映射到高维空间，学习非线性映射关系。

【具体步骤】

1）数据准备：采用任务 3 提取的 9 维时域特征（或 PCA 降维后的 2-3 维主成分），标签构建为 RUL = (158 - 当前文件序号) × 1 分钟，即距失效的剩余时间。将 RUL 线性映射至[0,1]区间，0 代表失效，1 代表全新。

2）数据划分：训练集可以采用前 110 个样本（文件 1-110，约 70%，寿命前 1 小时 50 分钟），测试集可以采用后 48 个样本（文件 111-158，约 30%，寿命最后 48 分钟）。严格按时间顺序划分，模拟用历史数据预测未来的真实工业场景。

3）模型训练：分别训练 OLS、Ridge、SVR 三个模型。Ridge 回归需要调参（alpha 值，建议尝试 0.1, 1, 10），SVR 需要调参（C 值和 gamma 值）。Ridge 和 SVR 在训练集内部使用 5 折交叉验证确定最优超参数。验证集从训练集后 20%中随机抽取，确保训练过程不接触测试集。

4）预测与反归一化：在测试集（111-158）上进行 RUL 预测。将预测值从[0,1]区间映射回实际剩余寿命（分钟）。

5）结果可视化：绘制 RUL 预测值与真实值对比曲线。横轴为文件序号（时间），纵轴为剩余寿命。绘制预测误差随时间变化图，观察误差是否在接近失效时增大。

6）性能评估：计算均方根误差（RMSE）和平均绝对误差（MAE），对不同模型的结果进行比较分析。

【评分建议】

1）完成数据准备与划分（10 分）

2）通过最小二乘回归（OLS）实现 RUL 预测（15 分）

3）通过岭回归（Ridge）实现 RUL 预测（15 分）

4）通过支持向量回归（SVR）实现 RUL 预测（15 分）

## 3.4 数据集下载链接与文献引用

【数据集下载】

来源 1：https://pan.baidu.com/s/1OaY82azTXHBwjiCjA_jRcw

来源 2：https://drive.google.com/open?id=1_ycmG46PARiykt82ShfnFfyQsaXv3_VK

【文献】

[1] 雷亚国, 韩天宇, 王彪, 李乃鹏, 闫涛, 杨军. XJTU-SY 滚动轴承加速寿命试验数据集解读. 机械工程学报, 55(16):1-6, 2019.

[2] Biao Wang, Yaguo Lei, Naipeng Li, Ningbo Li. A hybrid prognostics approach for estimating remaining useful life of rolling element bearings. *IEEE Transactions on Reliability*, 69(1): 401-412, 2020.

# 第四章 变转速条件下轴承振动信号分析实验

## 4.1 工业背景与问题描述

在实际工业应用中，许多旋转机械（如风力发电机、汽车发动机、航空发动机等）经常在变转速工况下运行。与恒定转速条件不同，变转速工况下的振动信号分析面临更大挑战：转速变化会导致故障特征频率发生偏移，传统基于恒定转速的故障诊断方法难以适用，易导致故障漏判、误判，引发设备停机、生产中断乃至安全事故。因此，研究变转速条件下轴承振动信号的特征提取和状态识别方法，对于提高故障诊断的准确性和可靠性具有重要意义。

本实验基于变转速条件下的轴承振动数据集，研究非稳态下故障特征提取与诊断方法，通过分析不同健康状态轴承在不同转速变化模式下的振动响应，掌握变转速信号的分析方法，实现轴承运行状态的有效识别。

## 4.2 数据集基本情况介绍

（1）数据集名称：变转速条件下轴承振动数据集（Bearing Vibration Data under Time-varying Rotational Speed Conditions）

（2）数据来源：渥太华大学

（3）试验平台：基于 SpectraQuest 机械故障模拟试验台（MFS-PK5M）搭建，由交流电机、变频调速系统、转轴、支撑轴承、测试轴承座组成，如图 4 所示。转轴由两个 ER16K 滚动轴承支撑，左侧为健康轴承，右侧为可更换健康/故障状态的测试轴承。

1）传感器配置：采用 ICP 加速度传感器（型号 623C01）采集振动信号，增量式编码器（EPC 775）采集实时转速；

2）轴承型号：ER16K 滚动轴承，结构参数为节圆直径 38.52 mm、滚珠直径 7.94 mm、滚珠数量 9 个；

3）故障特征频率：内圈故障特征频率 BPFI=5.43× 转轴转频，外圈故障特征频率 BPFO=3.57× 转轴转频。

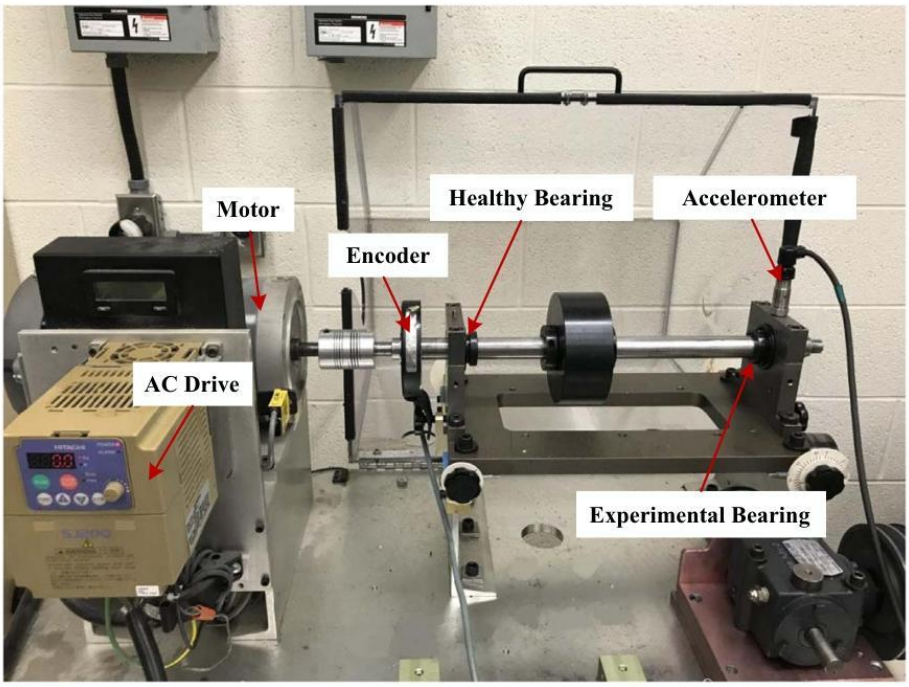


图 4 SpectraQuest 机械故障模拟试验台示意图

（4）工况设置：数据集覆盖 3 种健康状态与 4 种变转速模式，每种组合重复 3 次试验，共形成 36 组数据：

1）轴承状态：健康、内圈故障、外圈故障；

2）转速工况：升速、降速、先升后降、先降后升；

3）转速范围：约 10 Hz–30 Hz（对应 600–1800 rpm）区间内连续变化。

（5）数据规模与采集说明：

1）总计 36 组独立振动与转速同步采集数据，对应 36 个文件（.mat 格式）；

2）采样频率：200 kHz；

3）单组采样时长：10 秒；

4）单组采样点数：每组双通道各 200 万个采样点；

5）通道定义：Channel_1 为振动信号，Channel_2 为转速信号；

6）数据文件命名规则：[健康状态]-[转速模式]-[试验次数].mat，例如 H-A-1.mat 表示健康轴承在递增转速条件下的第 1 次试验数据。

7）数据集根据健康状态命名情况如下：

| 状态编号 | 健康状态 | 数据文件前缀 | 文件数量 |
|---|---|---|---|
| H | 健康轴承 | H- | 12 个 |
| I | 内圈故障 | I- | 12 个 |
| O | 外圈故障 | O- | 12 个 |

8）数据集根据转速变化模式情况如下：

| 模式编号 | 转速变化模式 | 数据文件标识 | 每种状态文件数 |
|---|---|---|---|
| A | 递增转速 | -A- | 3 个 |
| B | 递减转速 | -B- | 3 个 |
| C | 先增后减 | -C- | 3 个 |
| D | 先减后增 | -D- | 3 个 |

## 4.3 数据分析任务

**任务 1：数据统计分析与可视化**

【任务目标】通过对振动信号进行统计特征计算和可视化展示，直观区分健康、内圈故障、外圈故障轴承在变转速工况下的振动差异，分析转速与振动强度之间的关联规律。

【采用方法】

1）时域统计分析：计算振动信号的均值、标准差、均方根值（RMS）及峰值，量化信号能量与波动程度。

2）可视化方法：绘制振动信号与转速信号的时间序列对比图，构建转速-振动 RMS 散点图观察相关性，使用箱线图展示不同健康状态下统计特征的分布差异。

3）相关分析：计算转速与振动幅值的皮尔逊相关系数，判断两者线性相关性的强度。

【具体步骤】

1）数据选择：选用某一条件下的 3 个数据文件作为统一数据源，例如转速模式 A（升速工况）下的数据，包括 H-A-1.mat、I-A-1.mat、O-A-1.mat（MATLAB 数据格式），同步读取振动信号与转速信号。

2）波形绘制：绘制双轴时间序列图（上轴为转速随时间变化，下轴为振动加速度随时间变化）。

3）统计特征计算：对每段信号计算统计特征，均值反映信号中心趋势，标准差反映波动强度，RMS 反映整体能量水平，峰值反映冲击程度。

4）图形绘制与分析：构建转速-振动 RMS 散点图，观察是否存在线性或分段线性关系；对比三种健康状态的箱线图，分析特征分离度；绘制不同转速区间的振动响应曲线，观察转速升高时振动幅值的演化规律。

【评分建议】

1）时间序列图与分析结果可视化（10 分）

2）统计特征计算（5 分）

**任务 2：基于小波变换的数据去噪**

【任务目标】利用小波变换去除振动信号中的高频随机噪声与环境干扰，同时保留与故障相关的冲击成分，提升信号质量以支持后续特征提取与故障诊断。

【采用方法】离散小波变换（DWT）：采用离散小波变换（DWT）结合软阈值去噪策略，对含噪振动信号进行多分辨率分解与重构，实现信噪分离。

【具体步骤】

1）确定去噪对象：选取 I-A-1.mat 或 O-A-1.mat（故障特征更明显）作为处理对象。

2）小波分解：加载一条信号，选用一种小波基函数（db4、sym8、coif3 等）对信号进行分解（建议 5 层），得到 1 个近似系数 a5 和 5 个细节系数 d1 至 d5。

3）阈值处理：采用软阈值或硬阈值处理细节系数，阈值选取基于通用阈值（Universal Threshold）或启发式阈值（Heursure）。

4）信号重构：将处理后的系数与近似系数 a5 进行重构，得到去噪信号。

5）效果对比：在时域绘制原始信号与去噪信号的波形对比图，观察去噪后冲击脉冲的清晰度和基线平稳性。在频域分别计算两者的 FFT 幅值谱，重点对比谱峰尖锐程度和信噪比改善情况。

6）量化评估：计算信噪比（SNR = 10·log10(信号功率/噪声功率)）评估噪声抑制效果。计算均方根误差（RMSE）衡量去噪信号与原始信号的偏差。

【评分建议】

1）通过小波变换获得重构后的去噪信号（10 分）

2）分析原始信号与去噪信号的频谱差异（5 分）

3）计算信噪比（SNR）和均方根误差（RMSE）（5 分）

**任务 3：异常值检测**

【任务目标】识别振动信号中的异常波动点（离群值），比较统计学方法（3$\sigma$ 准则与箱线图法）的检测性能，并分析异常值分布与轴承健康状态的关联。

【采用方法】

1）分段检测：将长信号分割为短段，计算每段统计量以避免时变特性的影响。

2）3$\sigma$ 准则：假设信号服从正态分布，计算整体均值 $\mu$ 与标准差 $\sigma$，将超出[$\mu$-3$\sigma$, $\mu$+3$\sigma$]范围的点标记为异常值。

3）箱线图法：基于四分位数（Q1、Q3）计算四分位距 IQR = Q3 - Q1，将超出[Q1-1.5×IQR, Q3+1.5×IQR]范围的点标记为异常值（对非正态分布更鲁棒）。

【具体步骤】

1）信号分段：对三个文件 H-A-1.mat、I-A-1.mat、O-A-1.mat，设置一定的时间窗口长度，分别对每个数据文件中的信号进行分段，进而在异常值识别时，利用每一段的统计量来判断该窗口内异常值。

2）统计量计算：计算每段信号的均值、标准差、四分位数（Q1、Q2、Q3）。

3）应用 3$\sigma$ 准则：标记绝对值超出 $\mu\pm3\sigma$ 的采样点为异常值（红色标注）。

4）应用箱线图法：计算每段 IQR=Q3-Q1，标记超出 1.5 倍 IQR 边界的点为异常值（蓝色标注）。

5）结果分析：观察是否与转速突变段或故障冲击时刻重合，分析健康轴承与故障轴承的异常值密度差异。

【评分建议】

1）通过 3σ 准则识别异常值（10 分）

2）通过箱线图识别异常值（10 分）

3）结果分析（5 分）

**任务 4：聚类分析**

【任务目标】在无监督条件下（不依赖标签）对轴承运行状态进行自动划分，对比划分式聚类（k-means++）与密度式聚类（DBSCAN）的适用性，并验证聚类结果与实际健康状态的吻合程度。

【采用方法】

1）时域特征提取：提取统计特征，量化不同健康状态的信号特性。

2）k-means++聚类：基于划分的聚类算法，采用 k-means++初始化策略优化初始聚类中心选择，避免陷入局部最优解。

3）DBSCAN 聚类：基于密度的聚类算法，通过设定邻域半径 $\varepsilon$ 和最小样本数，自动识别高密度区域作为类簇，并将稀疏点标记为噪声，无需预设类别数。

4）降维可视化：采用 PCA 或 t-SNE 将高维特征降至 2 维，展示聚类结果的空间分布。

【具体步骤】

1）特征提取：对 H-A-1.mat、I-A-1.mat、O-A-1.mat 三个文件分别提取 8 个时域特征：RMS、峰值、峰峰值、标准差、偏度、峭度、波形因子、峰值因子，构建特征矩阵，行代表样本，列代表特征（8 维）。

2）数据标准化处理：对特征矩阵逐列进行 Z-score 标准化，使各特征均值为 0、标准差为 1，消除量纲差异。

3）k-means++聚类分析：设置聚类数 k=3（对应健康、内圈故障、外圈故障），运行算法得到每个样本的聚类标签（0、1、2）和聚类中心坐标，记录每个样本到所属聚类中心的距离（用于后续评估）。

4）DBSCAN 聚类分析：设置最小样本数（例如 5），邻域半径 $\varepsilon$（例如 0.5-2.0），运行 DBSCAN 算法得到聚类标签（-1 表示噪声点），记录核心点、边界点和噪声点的分布情况。

5）聚类效果评估：计算聚类准确率、轮廓系数（Silhouette Score），其中准确率为将聚类标签与真实标签（H/I/O）对比中正确分类的样本比例， 轮廓系数评估样本与所属类簇的紧密程度及与其他类簇的分离程度。

6）降维可视化：使用 PCA 或 t-SNE 将 8 维特征降至 2 维，绘制散点图：横纵坐标为前两个主成分，不同颜色代表聚类结果，用不同形状（如○/□/△）代表真实健康状态。同时，绘制 k-means++的聚类中心位置，标注 DBSCAN 识别出的噪声点。

【评分建议】

1）特征提取与标准化处理（5 分）

2）实现 k-means++聚类分析（10 分）

3）实现 DBSCAN 聚类分析（10 分）

4）聚类评价指标计算与分析（5 分）

5）PCA 或 t-SNE 降维可视化（10 分）

## 4.4 数据集下载链接与文献引用

【数据集下载】

Mendeley Data: https://data.mendeley.com/datasets/v43hmbwxpm/1

DOI: 10.17632/v43hmbwxpm.1

【文献】

Huan Huang, Natalie Baddour. Bearing vibration data collected under time-varying rotational speed conditions. Data in brief, 21, pp.1745-1749, 2018.

# 第五章 锂离子电池退化与健康状态分析实验

## 5.1 工业背景与问题描述

锂离子电池是分布式储能、电动汽车、电动叉车等工业与交通装备的核心动力单元，其健康状态（State of Health, SOH）精准评估与剩余使用寿命（Remaining Useful Life, RUL）可靠预测，对保障设备连续安全运行、降低运维成本、避免非计划停机具有关键作用。在实际工业应用中，电池往往面临复杂多变的工作条件，如电动叉车等，长期处于频繁启停、动态负载、多温度环境下运行，电池持续经历充放电循环，容量与功率性能不断衰减。当电池容量衰减至初始容量的 80% 时，通常判定达到寿命终点（End of Life, EOL）。

实际工况下电池老化呈现强非线性、时变性与多因素耦合特性，传统固定周期维护难以匹配真实退化规律，易造成过度维护或失效漏检。因此，本实验核心问题为：如何基于真实叉车运行数据揭示电池动态退化规律；如何提取有效健康特征；如何构建高精度 SOH 评估与寿命预测模型，为工业电池智能运维提供数据支撑与算法依据。

## 5.2 数据集基本情况介绍

（1）数据集名称：Lithium-ion battery degradation dataset based on a realistic forklift operation profile

（2）数据来源：丹麦奥尔堡大学（Aalborg University）

（3）测试对象：3 只商用方形磷酸铁锂（LFP）锂离子电池

（4）核心参数：额定容量 180 Ah，额定电压 3.2 V，电压区间 2.5 V–3.65 V

（5）老化条件：Cell 1@45℃、Cell 2@40℃、Cell 3@35℃；采用真实叉车工况负载谱。

（6）数据规模：总样本约数百万条秒级测量记录；Cell 1/Cell 2 各 58 轮老化循环，Cell 3 共 53 轮循环；单轮约对应 29 个全等效循环（FEC），总等效循环 600–1000 FEC。

（7）数据格式：全部为.csv 文件格式的时序数据，按电池编号与老化轮次分层存储，每轮包含老化运行数据（Ageing）与基准性能测试数据（RPT），如图 5 所示。RPT 文件包含 RPT 的结果，而 Ageing 文件包含电池对真实叉车负载工况的实际响应。

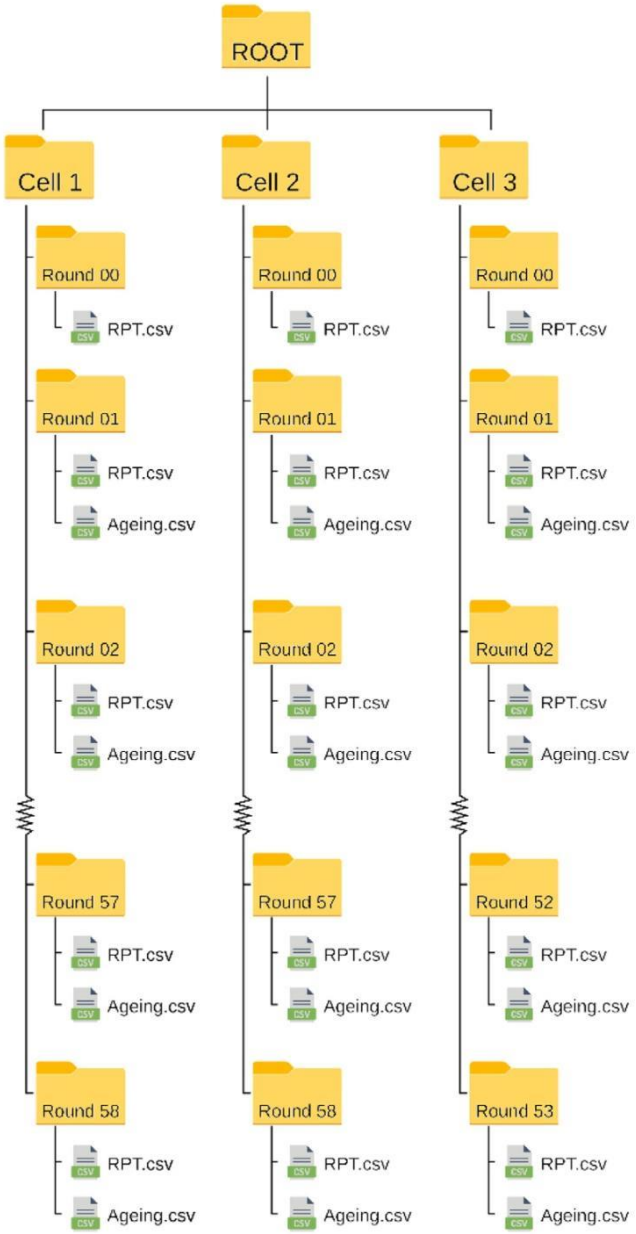


图 5 数据集中文件组成示意图

（8）采样信息：根据测试设备记录，时间间隔约 1 秒；基于真实叉车 4 个月运行数据提取，包含动态放电和分段充电；充电协议主要为 24A 恒流充电。

（9）特征说明：数据集包含多个 CSV 文件，数据集中所包含字段如下：

| 特征名称 | 数据类型 | 角色 | 说明 |
|---|---|---|---|
| Cell | 离散值 | 标识 | 电池编号（1、2、3） |
| Round | 离散值 | 标识 | 老化轮次，0–58 |
| Part | 离散值 | 标识 | 测试阶段（老化阶段/RPT 阶段） |
| Time | 连续值 | 时间 | 时间戳（秒） |
| Current | 连续值 | 特征 | 电流（A），正值为充电，负值为放电 |
| Voltage | 连续值 | 特征 | 端电压，单位伏特 |
| Energy | 连续值 | 特征 | 累积能量，单位瓦时 |
| Temperature | 连续值 | 特征 | 电池表面温度，单位℃ |
| Capacity | 连续值 | 目标变量 | 放电容量，由 RPT 测试得到 |
| SOH | 连续值 | 目标变量 | 健康状态，当前容量 / 初始容量 |

## 5.3 数据分析任务

**任务 1：数据统计分析与可视化**

【任务目标】全面掌握数据集统计分布与时序特征，直观呈现电池的容量衰减、电参数变化及温度影响规律。

【采用方法】

1）描述性统计：计算均值、标准差、极值、分位数，反映数据集中趋势与离散程度。

2）时序可视化：用折线图呈现电流、电压、温度等随时间的变化。

3）衰减曲线可视化：绘制容量-FEC、SOH-轮次关系图。

【具体步骤】

1）数据加载与筛选：加载 Cell 1 的老化数据，合并 Ageing 文件获取运行时序数据，提取 RPT 文件中的容量数据；考虑部分轮次数据缺失，可以去掉这些轮次的数据集。

2）描述性统计计算：对 current、voltage、temperature 计算均值、标准差、最小值、最大值、四分位数（Q1、Q2、Q3）。

3）典型工况可视化：选择某一轮早期和某一轮晚期的 Ageing 数据，绘制 current-time 和 voltage-time 双轴波形图，对比新旧电池在相同叉车工况下的电压响应差异。

4）衰减曲线绘制：以 FEC 为横轴、Capacity 为纵轴，绘制散点图；绘制每轮老化平均温度-轮次散点图，验证 45℃恒温控制稳定性。

【评分建议】

1）描述性统计指标计算（5 分）

2）时序曲线绘制（5 分）

3）衰减曲线绘制（5 分）

**任务 2：相关性分析**

【任务目标】量化电池健康状态与操作参数之间的线性相关关系，识别影响 SOH 的关键特征，为后续建模提供特征选择依据。

【采用方法】

1）皮尔逊相关系数（Pearson Correlation Coefficient）：衡量两个连续变量间线性相关程度的指标，取值范围为[-1,1]，绝对值越大表示相关性越强。

2）斯皮尔曼等级相关（Spearman's Rank Correlation）：非参数检验方法，用于衡量变量间的单调关系，适用于非线性但单调的退化关系。

【具体步骤】

1）特征构建：构建分析数据集，包含循环次数（FEC，累计值）、当前容量（Capacity，从 RPT 提取）、健康状态 SOH（当前容量/初始容量×100%）、平均放电电流（每轮 Ageing 电流均值）、电压波动范围（每轮电压最大值-最小值）、累积放电能量（对每轮 Energy 列积分累计）。

2）相关系数计算：计算各变量与 SOH 的皮尔逊相关系数，识别与 SOH 强相关的特征（如设置阈值为 0.7）；计算 FEC 与 Capacity 的斯皮尔曼等级相关系数，验证单调递减关系。

3）滞后相关性分析：计算 current 与 voltage 的互相关系数，识别电参数的动态响应延迟。

4）结果分析：分析说明为何 FEC 是预测 SOH 的最佳单一特征，讨论温度波动与容量衰减的弱相关性（因恒温控制）。

【评分建议】

1）皮尔逊相关系数计算（5 分）

2）斯皮尔曼相关系数计算（5 分）

3）滞后相关性分析（5 分）

4）相关性结果分析（5 分）

**任务 3：SOH 预测**

【任务目标】基于循环次数和其他特征预测当前电池容量，建立电池健康状态（SOH）的预测模型。

【采用方法】

1）岭回归（Ridge Regression）：在普通最小二乘法基础上加入 L2 正则化项，通过惩罚大系数防止过拟合，适用于特征间存在多重共线性的场景。

2）支持向量回归（Support Vector Regression, SVR）：采用核函数将特征映射到高维空间，学习非线性映射关系。

【具体步骤】

1）数据准备：使用 Cell 1 的 58 个轮次的样本点（每轮为一个样本），其中特征包括 FEC、累积放电能量、平均电压、电流标准差（反映工况剧烈程度）等，目标为 SOH 值（%）。

2）数据集划分：前 80%轮次（Round 0-46）作为训练集，后 20%（Round 47-58）作为测试集，模拟实际预测场景，即用历史数据预测未来状态。

3）特征标准化：对特征进行 Z-score 标准化，消除量纲差异。

4）岭回归建模：在 python 中，可以使用 sklearn.linear_model.Ridge。通过 5 折交叉验证选择最优 alpha 参数（如范围 0.1-10.0），训练模型获得回归系数。

5）SVR 建模：在 python 中，可以使用 sklearn.svm.SVR，设置超参数，选择核函数，训练模型，并绘制预测值-真实值散点图。

6）模型评估与对比：计算 RMSE（均方根误差）、MAE（平均绝对误差）、$R^2$ 决定系数、MAPE（平均绝对百分比误差）。

7）结果可视化：绘制测试集 SOH 预测曲线（时间序列图），叠加真实值与预测值，并绘制误差时序曲线。

【评分建议】

1）岭回归实现与调参（10 分）

2）SVR 模型实现（10 分）

3）评估指标计算（5 分）

4）结果可视化与模型对比分析（10 分）

**任务 4：电池健康状态分级**

【任务目标】将连续的 SOH 值离散化为健康等级，构建分类模型实现电池状态的自动判定，为维护决策提供离散化标签。

【采用方法】

1）决策树分类（Decision Tree Classifier）：生成可解释的规则树，能够捕捉非线性决策边界，且模型结果可视化便于工程人员理解。

2）朴素贝叶斯分类（Naive Bayes）：基于贝叶斯定理与特征条件独立假设的概率分类器，计算效率高，适用于小样本多分类问题，对噪声数据具有鲁棒性。

【具体步骤】

1）健康等级定义：基于 SOH 值建立四分类体系，如优秀（Excellent）：SOH ≥ 95%（初始阶段），良好（Good）：85% ≤ SOH < 95%（轻微衰减），一般（Fair）：70% ≤ SOH < 85%（中度衰减，需关注），需更换（Poor）：SOH < 70%（寿命终止，EOL）。

2）特征构建：分类特征主要包括循环次数（FEC）、当前平均电压（反映内阻增长）、电压波动系数（标准差/均值，反映极化程度）、温度累积量（每轮平均温度×时间，反映热应力累积）等。

3）数据集划分：由于类别可能不平衡（优秀样本少，良好/一般样本多），采用分层抽样：训练集 70%，测试集 30%，设置随机种子保证可重复性。

4）决策树建模：在 python 中，可以使用 sklearn.tree.DecisionTreeClassifier，设置最大深度、最小叶节点样本数等参数，训练后导出文本规则（export_text）和树形图（plot_tree）。

5）朴素贝叶斯建模：在 python 中，可以使用 sklearn.naive_bayes.GaussianNB，训练模型并输出各类别的先验概率与条件概率参数。

6）模型评估与混淆矩阵可视化：计算准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1 分数等评价指标，并比较两个模型性能；绘制混淆矩阵热力图（百分比形式）。

【评分建议】

1）决策树模型实现（10 分）

2）朴素贝叶斯模型实现（10 分）

3）模型性能评估指标计算（5 分）

4）混淆矩阵可视化（5 分）

## 5.4 数据集下载链接与文献引用

【数据集下载】

下载链接：https://data.mendeley.com/datasets/yz4pttm73n/2

DOI：10.17632/yz4pttm73n.2

【文献】

Søren B. Vilsen, Daniel-Ioan Stroe. Dataset of lithium-ion battery degradation based on a forklift mission profile for state-of-health estimation and lifetime prediction. Data in Brief, 52, p.109861, 2024.

# 第六章 粒子加速器电源系统故障分类实验

## 6.1 工业背景与问题描述

粒子加速器是大型科学装置的核心设备，广泛应用于核物理研究、材料科学、医学治疗等领域。散裂中子源（Spallation Neutron Source, SNS）是美国橡树岭国家实验室的大型科学设施，其线性加速器需要高压变换调制器（High Voltage Converter Modulator, HVCM）为速调管（Klystron）提供稳定的高功率射频电源。

HVCM 系统的可靠性直接影响加速器的正常运行。由于系统复杂、工作条件苛刻，HVCM 经常出现各类故障，是 SNS 停机的主要原因之一。传统的故障检测依赖人工监控和经验判断，难以及时发现早期异常。通过对 HVCM 运行过程中的电子信号进行实时监测和分析，利用机器学习方法自动识别异常模式，可以实现故障的早期预警，减少非计划停机时间，提高科学装置的运行效率。

本实验基于 SNS 实际采集的 HVCM 信号数据，开展信号处理与故障分类，探索工业信号数据的智能诊断方法。

## 6.2 数据集基本情况介绍

（1）数据集名称：Real Electronic Signal Data from Particle Accelerator Power Systems for Machine Learning Anomaly Detection

（2）数据来源：美国橡树岭国家实验室

（3）采样设备：数据采自全部 15 个 HVCM 系统，根据类型分为四类主要子系统：1 个调制器作为射频四极（RFQ）、2 个调制器作为漂移管直线加速器（DTL）、4 个调制器作为耦合腔直线加速器（CCL）、8 个调制器作为超导直线加速器（SCL），如图 6 所示。

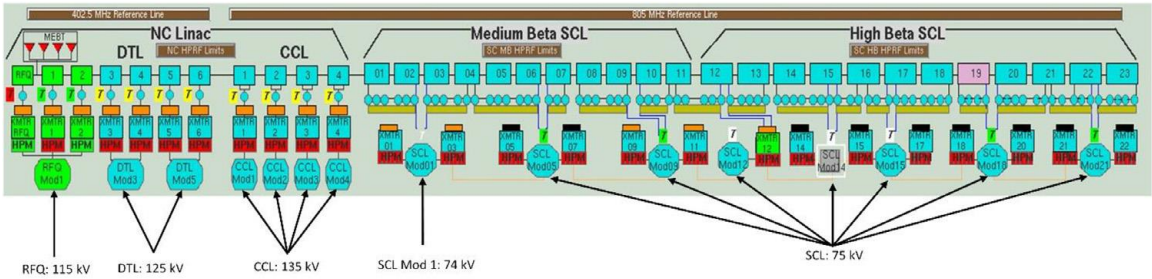


图 6 HVCM 系统示意图

（4）数据描述：该数据集包含在 2020-2022 年间运行的真实波形数据；每个系统（RFQ、CCL、DTL、SCL）有两个数据文件，一个包含波形数据，一个包含这些波形的标签；每条包含 14 个特征变量，涵盖 IGBT 开关电流、变压器磁通、调制器电压/电流、电容组状态及电压变化率等关键电气参数；数据包含在.npy 文件中，且提供 load_data.py 示例脚本，同时提供 sample_data.xlsx 供人工查看。

（5）数据集特点：

1）高采样率时间序列（400 ns 采样间隔）；

2）正常与故障样本不平衡；

3）包含 14 维多元信号，变量间存在电磁耦合关系；

4）故障类型多样，涵盖光纤故障、电压偏低、电压变化率过高等。

（6）特征说明：

| 特征类别 | 特征名称 | 数据类型 | 角色 | 说明 |
|---|---|---|---|---|
| 时间基准 | time_steps | 连续值 | ID | 时间步序号（0-4499） |
| IGBT 电流 | A+IGBT-I, A+*IGBT-I, B+IGBT-I, B+*IGBT-I, C+IGBT-I, C+*IGBT-I | 连续值 | 特征 | 三相 IGBT 开关电流（单位：A） |
| 磁通量 | A-Flux, B-Flux, C-Flux | 连续值 | 特征 | 三相变压器磁通密度（经缩放处理） |
| 调制器状态 | Mod-V, Mod-I | 连续值 | 特征 | 调制器电压（V）与电流（A） |
| 电容组状态 | CB-V, CB-I | 连续值 | 特征 | 电容组电压与电流 |
| 电压变化率 | DV/DT | 连续值 | 特征 | 调制器电压时间导数 |
| 标签 | status | 类别型 | 目标变量 | Run（正常）/ Fault（故障） |
| 标签 | type | 类别型 | 目标变量 | Normal 或具体故障类型 |

## 6.3 数据分析任务

**任务 1：信号可视化与特征分析**

【任务目标】理解 HVCM 高频信号的基本形态，对比正常与故障信号的波形差异，提取基础统计特征，为后续建模提供先验知识。

【采用方法】

1）时间序列可视化：利用折线图展示信号随时间演变规律，观察脉冲上升沿、平顶段、下降沿的物理特性。

2）统计特征计算：计算时域统计量，刻画信号形态。

【具体步骤】

1）加载 RFQ 子系统数据：加载 RFQ.npy 和 RFQ_labels.npy，提取 Mod-V（调制器电压）、Mod-I（调制器电流）、A-Flux（A 相磁通）等关键信号。

2）正常样本随机抽样：从 status=Run 的样本中随机抽取 5 条脉冲，绘制上述三个信号的时间序列图（横轴时间 ms，纵轴物理量）。

3）故障样本对比抽样：针对 type=DV/DT High Fault 和 Fiber Fault 两类典型故障，各抽取 5 条脉冲，与正常样本在同一坐标系下绘制对比曲线。

4）统计特征计算：对 Mod-I 信号计算以下指标：均值、标准差、峰值、峰值因子、波形因子等。

5）箱线图分析：以 type 为分组变量，绘制 Mod-V 和 Mod-I 的箱线图，观察正常与各类故障的分布差异。

【评分建议】

1）正常/故障条件下时间序列图绘制（10 分）

2）统计特征计算与比较分析（5 分）

3）箱线图绘制与分析（5 分）

**任务 2：数据去噪处理**

【任务目标】去除 HVCM 信号中的高频测量噪声，保留有用特征，提升后续分析的信噪比。

【采用方法】离散小波变换（DWT）去噪：对非平稳信号进行多尺度分解，通过阈值处理抑制高频噪声分量，适用于具有瞬态跳变特征的功率电子信号。

【具体步骤】

1）选择待处理信号：选取 Mod-V（调制器电压）信号，提取第 1 条正常脉冲的 4500 个采样点作为处理对象。

2）小波分解：在 python 中，可以使用 PyWavelets 库，选择 db4 小波基，进行分解，得到近似系数和细节系数。

3）阈值处理：对细节系数应用软阈值（Soft Thresholding）。

4）信号重构：使用处理后的系数进行逆小波变换，重构去噪后的 Mod-V 信号。

5）效果评估：计算信噪比，绘制去噪前后信号对比图，特别关注脉冲上升沿的平滑度与特征保留情况。

6）参数敏感性分析：分别使用 db2 和 sym5 小波基重复上述过程，对比不同小波基对 IGBT 开关瞬态（高频成分）的保留效果。

【评分建议】

1）小波去噪算法实现（10 分）

2）去噪前后 SNR 数值对比（5 分）

3）不同小波基对比分析（10 分）

**任务 3：异常值检测**

【任务目标】探索多维信号之间的动态响应关系，识别与故障状态相关性最强的特征组合，降低特征维度，避免后续分类模型的维度灾难。

【采用方法】

1）皮尔逊相关系数：计算特征与故障标签的线性相关性，辅助特征筛选。

2）互相关分析（Cross-Correlation）：衡量两个时间序列在不同时间偏移（时滞）下的线性相关程度，识别变量间的滞后特性。

【具体步骤】

1）数据降采样：由于原始采样率过高，对每条脉冲进行降采样，便于计算。

2）计算互相关矩阵：计算各维度信号之间的滞皮尔逊相关系数，绘制热力图（Heatmap）。

3）时滞分析：针对 Mod-V（输入类信号）与 Mod-I（响应类信号），计算时滞范围-50 至+50 采样的互相关系数，绘制互相关系数随迟延变化的曲线。

4）识别峰值与时滞：确定互相关系数峰值以及对应的时滞值，分析其物理意义，即调制器电压对电流的响应延迟。

5）特征重要性排序：计算 14 个特征与 status 标签（0/1 编码）的点二列相关系数，选择相关系数绝对值 Top-5 的特征作为下一个任务的输入变量。

【评分建议】

1）互相关热力图可视化（10 分）

2）Mod-V 与 Mod-I 最优时滞识别（5 分）

3）Top-5 特征选择（5 分）

**任务 4：故障分类模型**

【任务目标】建立机器学习分类模型，自动识别 HVCM 信号的正常/故障状态，评估模型在单个子系统上的泛化能力。

【采用方法】支持向量机（SVM）：适用于高维小样本数据的二分类任务，通过核函数映射处理非线性决策边界。

【具体步骤】

1）特征选择：基于任务 3 结果选择的 5 个最具区分度的时域特征，对每条脉冲提取特征向量，构建特征矩阵。

2）数据标准化：对 5 维特征进行 Z-score 标准化。

3）数据集划分：按 status 标签分层，划分训练集（70%）、验证集（15%）、测试集（15%）。

4）模型训练：使用 RBF 核 SVM，设置超参数，在训练集上训练模型。

5）超参数调优：在验证集上使用 GridSearchCV 对超参数进行网格搜索，5 折交叉验证，选择 F1-score 最优的参数组合。

6）模型评估：在测试集上进行预测，计算准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1-score；绘制混淆矩阵和 ROC 曲线，计算 AUC 值。

7）故障类型细分：针对测试集中的 Fault 样本，统计模型对不同类型故障（Fiber Fault vs DV/DT High）的识别准确率。

【评分建议】

1）SVM 模型实现（含超参数调优过程）（20 分）

2）性能指标计算（10 分）

3）混淆矩阵与结果分析（5 分）

## 6.4 数据集下载链接与文献引用

【数据集下载】

下载链接：https://data.mendeley.com/datasets/kbbrw99vh8/5

DOI：10.17632/kbbrw99vh8.5

【文献】

Majdi Radaideh, Chris Pappas, Sarah Cousineau. Real electronic signal data from particle accelerator power systems for machine learning anomaly detection. Data in Brief, 43, p.108473, 2022.

# 第七章 火力发电厂蒸汽量软测量实验

## 7.1 工业背景与问题描述

火力发电是目前全球范围内最主要的电力供应方式之一，为工业生产、商业活动和居民生活提供了不可或缺的能源支持。其核心发电原理是利用煤炭、天然气等燃料燃烧释放的热能，将水加热转化为高温高压蒸汽，蒸汽推动汽轮机高速旋转，进而带动发电机产生电能。蒸汽量作为表征锅炉热力输出与汽轮机做功能力的关键参数，其精准监测与预测是优化燃烧控制、协调机炉运行、提升变负荷响应能力及保障设备安全运行的重要基础。在深度调峰、快速变负荷等灵活运行场景下，实时掌握蒸汽量的动态变化，对于实现机炉协同控制、降低煤耗、减少设备热应力疲劳具有显著的工程价值。

在实际运行中，电厂通常采用蒸汽流量计进行直接监测，但受限于测量环境的振动、腐蚀、结垢等因素，仪表的长期稳定性和测量精度难以保证，易出现数据漂移、零点偏移甚至失效等问题。此外，传统依赖人工经验分析和基于热力学公式的计算方法，计算过程繁琐、实时性差，难以适应现代化电厂对运行状态快速感知与精准调控的要求。

本实验利用与蒸汽量密切相关的辅助变量（如锅炉给水流量、汽轮机转速、主蒸汽压力、温度等），结合数据驱动方法，构建高精度的软测量模型，实现对蒸汽量的实时、可靠估计。

## 7.2 数据集基本情况介绍

（1）数据集名称：Industrial Steam Volume DataSet

（2）数据来源：https://github.com/surperstar-xu/zhengqi

（3）总样本数：2888 条记录

（4）数据描述：该数据集包含多组工业时序数据，共 38 个数据特征，反映了火电厂锅炉系统在实际运行工况下的行为模式。每个时间序列对应锅炉一段连续运行周期的参数采集记录，以各类核心运行辅助变量为动态输入，同步测量系统最终产出的蒸汽量为输出指标。火力发电工艺流程图如图 7 所示。

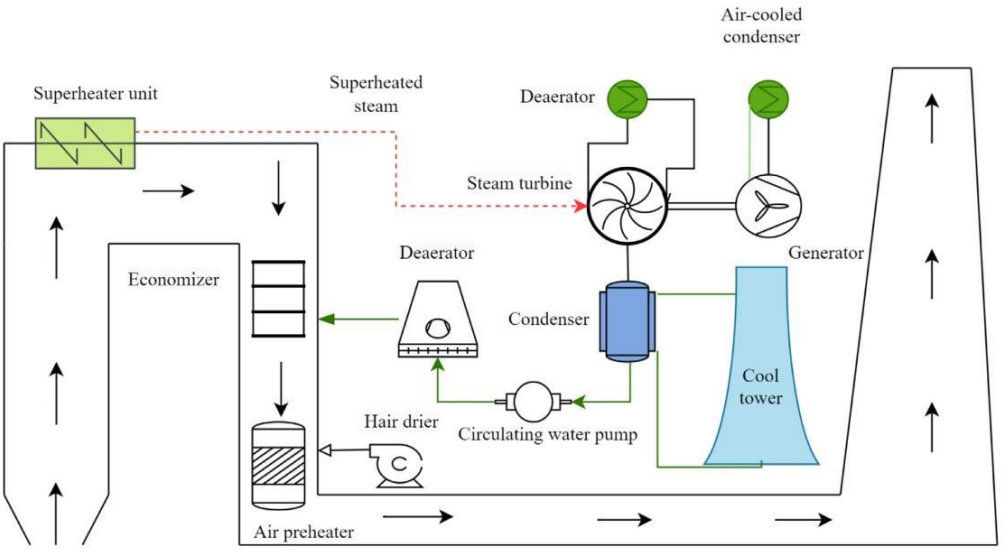


图 7 火力发电工艺流程图

## 7.3 数据分析任务

**任务 1：最小二乘线性回归建模与局限性分析**

【任务目标】建立输入过程变量到蒸汽产量的线性预测模型，分析最小二乘法在工业蒸汽数据场景下的局限性。

【采用方法】

1）最小二乘线性回归（OLS）：拟合线性关系，得到基础预测模型。

2）指标评价：采用 MSE、RMSE、MAE、MAPE、$R^2$ 评估模型拟合与预测效果。

【具体步骤】

1）数据准备：划分训练集与测试集，分离锅炉膛压、膛温、给水流量等过程变量和蒸汽产量。

2）模型训练：在训练集上训练 OLS 模型，得到回归系数与截距项。

3）模型预测与评估：在测试集上进行预测，计算 MSE、RMSE、MAE、MAPE、$R^2$ 指标。

4）局限性分析：结合数据特性（多重共线性、噪声、非线性），分析 OLS 在蒸汽数据集上的过拟合、系数不稳定等问题。

【评分建议】

1）OLS 模型实现与参数输出（15 分）

2）各项评价指标计算（5 分）

**任务 2：岭回归与 LASSO 建模与对比分析**

【任务目标】引入正则化约束缓解 OLS 的过拟合问题，对比岭回归与 LASSO 在蒸汽量预测中的性能差异，分析正则化参数的影响。

【采用方法】

1）岭回归（Ridge Regression）：在普通最小二乘法基础上加入 L2 正则化项，通过惩罚大系数防止过拟合，适用于特征间存在多重共线性的场景。

2）LASSO 回归：在普通最小二乘法基础上加入 L1 正则化项，使某些系数精确压缩至 0，适用于特征间存在多重共线性的场景。

【具体步骤】

1）数据准备：划分训练集与测试集，分离锅炉膛压、膛温、给水流量等过程变量和蒸汽产量。

2）岭回归：选择正则化强度参数，在训练集上训练模型，并在测试集上进行预测。

3）LASSO：选择正则化强度参数，在训练集上训练模型，并在测试集上进行预测。

4）模型对比：对比岭回归与 LASSO 在预测精度、系数稀疏性、特征选择能力上的优劣势。

【评分建议】

1）岭回归模型实现（15 分）

2）LASSO 模型实现（15 分）

3）正则化参数影响分析（10 分）

4）模型对比与结果解释（5 分）

**任务 3：SVR 建模分析**

【任务目标】建立非线性预测模型捕捉蒸汽量与过程变量间的复杂关系，对比 SVR 与正则化线性模型的性能差异。

【采用方法】

支持向量回归（Support Vector Regression, SVR）：采用核函数将特征映射到高维空间，学习非线性映射关系。

【具体步骤】

1）数据准备：划分训练集与测试集，分离锅炉膛压、膛温、给水流量等过程变量和蒸汽产量。

2）SVR：选择核函数（如 RBF），设置超参数（如 C=1.0, epsilon=0.1），在训练集上训练模型，并在测试集上进行预测。

3）参数影响分析：分析核函数类型、C、epsilon 等参数对模型拟合能力与泛化能力的影响。

4）综合对比：将 SVR 与 OLS、岭回归 / LASSO 进行对比，分析各模型在蒸汽量预测场景下的适用性、精度与优缺点。

【评分建议】

1）SVR 模型实现（15 分）

2）不同核函数与参数影响分析（10 分）

3）多模型综合对比（10 分）

## 7.4 数据集下载链接与文献引用

【数据集下载】

https://github.com/surperstar-xu/zhengqi

【文献】

Jinpeng Xu, Shiwei Gao, Xiaochao Dang, Wenfeng Zhao, Qingsong Zhang, Sulong Qiu. BO-MADRSN: Bayesian optimized multi-attention residual shrinkage networks for industrial soft sensor modeling. Measurement 224 (2024), 113477, 2024.

# 附录 实验环境配置与依赖库说明

## Python 环境要求

- Python >= 3.7
- 操作系统：Windows、Linux 或 macOS

## 必需的 Python 库

【核心库】

pip install numpy pandas matplotlib seaborn scikit-learn scipy openpyxl

【扩展库（根据实验需要选择安装）】

- 小波变换：pip install PyWavelets
- 数据处理：pip install openpyxl xlrd

## 库功能说明

- numpy: 数值计算，提供高效的数组运算
- pandas: 数据处理，提供 DataFrame 数据结构
- matplotlib: 数据可视化，绘制各类图表
- seaborn: 统计可视化，基于 matplotlib 的高级接口
- scikit-learn: 机器学习算法（回归、聚类、分类）
- scipy: 信号处理、科学计算
- PyWavelets: 小波变换去噪
- openpyxl: Excel 文件读写